


[MBI.A] Asembler DNA, sparowane końce - dokumentacja końcowa

Michał Aniserowicz, Jakub Turek

Opis problemu

Zadanie polega na implementacji aplikacji, która umożliwia tworzenie *scaffoldów* na podstawie dostarczonych zbiorów *contigów* oraz sekwencji PET.



Założenia

W ogólnym przypadku rekonstrukcja sekwencji *contigów* nie jest możliwa. Z tego względu, na potrzeby projektu przyjęto następujące założenia:

- Początki i końce łańcuchów PET to sekwencje unikalne. Wystąpienie takiej sekwencji w jednym z *contigów* oznacza, że jest to odpowiednio początek lub koniec sekwencji PET.
- Badane są wyłącznie takie permutacje *contigów*, dla których wystąpienie początku sekwencji PET implikuje przynajmniej częściowe wystąpienie jej końca w dalszej części łańcucha. Innymi słowy początek lub koniec sekwencji PET nie może w całości wystąpić w przerwie (*gap*) *scaffoldu*.
 - Wyjątkiem od tej reguły jest początek i koniec *scaffoldu*, gdzie mogą występować, odpowiednio, niesparowane końce lub początki sekwencji PET.
- Sekwencje należące do różnych par sparowanych końców mogą częściowo zachodzić na siebie.

Algorytm

Do rozwiązania zadania użyty został algorytm typu brute-force działający na wstępnie odfiltrowanym zbiorze kombinacji *contigów*. Algorytm przebiega według następującego schematu:

1. Wyznaczane są wszystkie permutacje zadanego zbioru *contigów*.
2. Permutacje zostają wstępnie sprawdzone:
 - następuje próba znalezienia sekwencji PET, której początek i koniec w całości zawiera się w dowolnej parze *contigów*:
 - jeśli taka sekwencja nie zostanie znaleziona, wszystkie permutacje zostają uwzględnione w kolejnych krokach algorytmu;
 - każda permutacja jest sprawdzana pod względem kolejności wystąpienia *contigów* zawierających znalezioną sekwencję:
 - jeśli *contig* zawierający początek sekwencji znajduje się przed *contigiem* zawierającym jej koniec, to dana permutacja zostaje uwzględniona w kolejnych krokach algorytmu,
 - w przeciwnym wypadku, permutacja zostaje odrzucona.
3. Na podstawie każdej z zaakceptowanych permutacji budowany jest *scaffold*:
 - dla każdej sekwencji PET:
 - następuje próba znalezienia *contiga* zawierającego (w całości lub częściowo¹) początek sekwencji,
 - przeglądane są *contigi* występujące po znalezionym, w celu odnalezienia *contiga* zawierającego koniec sekwencji,
 - jeśli odległość pomiędzy znalezioną parą *contigów* dopuszcza istnienie pomiędzy nimi sekwencji PET, to pomiędzy te *contigi* wstawiany jest odpowiedniej długości *gap*,
 - jeśli w którymkolwiek z powyższych kroków nastąpiło niepowodzenie (odpowiedni *contig* nie został odnaleziony lub sprawdzenie odległości dało wynik negatywny), to wykonywane jest sprawdzenie, czy pierwszy *contig* zawiera koniec sekwencji lub czy ostatni *contig* zawiera jej początek - taka sytuacja uznawana jest za poprawną,
 - aktualizowany jest ranking R , określający liczbę pokrywających się zasad początku lub końca sekwencji PET z odnalezionymi *contigami*.
 - jeżeli $R > 0$, to dany *scaffold* dodawany jest listy wynikowej algorytmu.
4. Uzyskana lista *scaffoldów* sortowana jest według malejących wartości R .

¹ Częściowe zawieranie sekwencji PET występuje, gdy *contig* zaczyna się końcem fragmentu (tzn. początku lub końca) danej sekwencji lub kończy początkiem fragmentu tej sekwencji.

Implementacja

Projekt został zaimplementowany w języku C# (platforma .NET). Testy jednostkowe zostały napisane w oparciu o platformę NUnit², z użyciem biblioteki Rhino Mocks³.

Aplikacja posiada interfejs okienkowy stworzony w technologii WPF, umożliwiający odczyt danych wejściowych z/zapis danych wyjściowych do pliku. Na dane wejściowe składają się:

- Opis *conitgów* w postaci łańcuchów tekstowych oddzielonych znakami nowej linii.

```
ACAGCTTA
CCGGGTAC
TACAGCTT
```

- Opis sekwencji PET w postaci dwóch sekwencji (początek, koniec) oraz długości łańcucha. Dane w sekwencji oddzielone przecinkami, natomiast kolejne PET'y oddzielone znakami nowej linii.

```
GATC,CCAT,100
GGCT,AGAA,1500
```

Dane wyjściowe to uporządkowana sekwencja *contigów* oddzielonych znakami spacji reprezentującymi długość przerwy (*gap*).

```
CCGGGTAC      TACAGCTT  ACAGCTTA
```

Przykład

- Plik wejściowy:

```
ACAGCTTA
CCGGGTAC
TACAGCAA

CCG,TACA,15
GCA,GCT,13
```

- Plik wyjściowy:

```
CCGGGTAC      TACAGCAA  ACAGCTTA
```

²<http://www.nunit.org/>

³<http://www.ayende.com/wiki/Rhino+Mocks.ashx>

Testowanie

TODO